

[1] 본 수업을 통해 성장한 내용

이론적인 내용부터 실무에서 AI가 사용되는 상황까지 상세한 설명을 통해, 전반적인 AI 동작과 각 사용처에 따른 모델 및 학습 전략 설계법에 대해서 학습할 수 있었습니다.

배운 내용을 정리해보면, 크게 인공지능 설계는 (0) 문제 정의 (1) 학습 데이터 준비 (2) AI 아키텍처 설계 (3) 학습 전략 수립 (4) 성능 평가 및 개선으로 이루어집니다.

특히 제한된 리소스(온디바이스) 상황에서 사물(손동작)을 인식하여 분류(가위,바위,보)하는 AI 모델을 설계하는 기말 프로젝트에서 배운 내용들을 직접 적용해보며 인공지능 코드를 설계하는 법을 익힐 수 있었습니다.

[2] 기말 프로젝트: 라즈베리 파이에서 효율적인 가위바위보 인식 모델 설계

- 목표: 다양한 Backbone 모델과 경량화 기법을 적용해보고 성능 평가하기

- 과정

(1) ResNet vs DenseNet 비교: **ResNet**이 조금 더 나은 성능을 보였습니다.

(2) (**ResNet** 선택) PTA vs QAT 비교: **QAT**가 조금 더 안정적인 모습을 보였습니다.

(3) (**ResNet & QAT** 선택) 없음 vs Clustering vs Pruning vs (Clustering + Pruning) 비교

- 비교 및 평가

실험 결과, Clustering 혹은 pruning만 적용하였을 때 큰 성능 저하가 발생하지 않았습니다. 하지만 Clustering과 pruning을 함께 적용한 모델의 경우, 성능 저하가 정성적으로 관찰되었습니다. 즉, 과도한 경량화 기법 적용은 모델 성능에 유의미한 영향을 줄 수 있음을 확인할 수 있습니다.

또한 경량화 기법보다 **배경**에 따른 인식률 차이가 더 크게 발생하였습니다. 즉, 불필요한 배경 정보가 예측 정확도 저하를 유발한 것으로 판단됩니다. 이에 따라 두 가지 해결책을 제시할 수 있습니다. 먼저, 다양한 배경에서 촬영한 데이터셋을 준비하여 학습하는 방법입니다. 하지만 해당 방식은 많은 시간과 노력이 필요한 작업입니다. 따라서 YOLO와 같은 객체 탐지 모델을 사용하여 불규칙한 배경 정보에 의해 예측 정확도가 저하되지 않도록 하는 것이 좋은 선택일 수 있습니다. 실제 실험 결과, 객체 탐지 모델의 경우 배경 변화에 의해 쉽게 영향을 받지 않는 것을 확인할 수 있었습니다.

경량화 세부 조건

[pruning]

- ConstantSparsity(0.75, begin_step=0, frequency=100)
- 마지막 convolution stage (conv5)와 마지막 Dense layer에 적용

[clustering]

- Number_of_clusters = 4
- 마지막 Dense layer에만 적용