

Edge-AI Interaction: Raspberry Pi 기반 가위바위보 인식 및 LLM 설명 시스템

2025324033 선우재

본 프로젝트는 Raspberry Pi 5, 카메라, 터치스크린을 활용하여 가위바위보 손동작을 실시간으로 인식하고, 그 결과를 경량 언어 모델이 자연어로 설명하는 Edge-AI 시스템을 구현하는 것을 목표로 하였다.

전체 시스템은 카메라 입력, TFLite 기반 비전 모델 추론, Python 기반 승패 판단, 경량 LLM 설명 생성, 화면 출력의 순서로 동작한다. 먼저 카메라를 통해 사용자의 손 모양을 입력받고, 학습된 RPS_PreTrained_DenseNet_Augmentation_QAT.tflite 모델이 이를 rock, scissors, paper 중 하나로 분류한다. 이후 Python 코드에서 가위바위보 규칙에 따라 사용자와 AI의 승패를 결정하고, Ollama 기반의 작은 언어 모델이 해당 결과를 설명하는 문장을 생성한다.

이 프로젝트의 핵심은 LLM이 직접 이미지를 이해하거나 승패를 추론하도록 만드는 것이 아니라, TFLite 비전 모델과 deterministic rule-based logic이 계산한 결과를 LLM이 사용자 친화적인 설명으로 변환하도록 구성한 점이다. 특히 Raspberry Pi 5는 GPU 없이 CPU-only 환경에서 동작하므로, LLM을 매 프레임마다 실행하지 않고 일정 시간 간격으로만 호출하여 시스템 부하를 줄였다. 또한 LLM이 잘못된 승패 설명을 생성하는 경우를 대비해 guard logic을 추가하여, 잘못된 출력은 안전한 deterministic 문장으로 대체하였다.

최종 시스템은 약 15 FPS 수준으로 카메라 기반 손동작 인식을 수행하였고, LLM 호출 시 약 2-7 초 정도의 latency로 자연어 설명을 생성하였다. 이를 통해 제한된 하드웨어에서도 비전 모델과 경량 언어 모델을 결합한 상호작용형 AI 데모를 구현할 수 있음을 확인하였다. 사용한 LM은 Qwen2.5 1.5B 모델이며, CPU에서 추론을 돌렸다.

이번 프로젝트를 통해 Edge device에서 AI 모델을 실제로 실행할 때는 모델 정확도뿐만 아니라 지연 시간, FPS, 메모리 사용량, CPU 점유율 같은 시스템 성능 요소가 매우 중요하다는 것을 배웠다. 특히 Raspberry Pi 5와 같은 제한된 환경에서는 TFLite 기반 비전 모델은 비교적 실시간으로 동작할 수 있지만, LLM 추론은 CPU 자원을 많이 사용하기 때문에 호출 빈도를 조절해야 했다.

또한 작은 LLM은 단순한 가위바위보 규칙도 잘못 해석하는 경우가 있었다. 예를 들어 사용자가 rock을 내고 AI가 scissors를 냈을 때도 AI가 이겼다고 잘못 설명하는 문제가 발생하였다. 이를 통해 경량 LLM을 실제 시스템에 사용할 때는 모든 판단을 LLM에 맡기기보다, 중요한 결정은 deterministic logic으로 처리하고 LLM은 설명 생성 역할로 제한하는 것이 더 안정적이라는 점을 배웠다. 마지막으로, AI 시스템은 모델 하나만으로 완성되는 것이 아니라 입력 처리, 모델 추론, 후처리, 사용자 인터페이스, 예외 처리, 성능 최적화가 함께 설계되어야 한다는 점을 경험하였다. 본 프로젝트는 작은 규모의 데모였지만, 실제 edge-AI application을 설계할 때 필요한 전체 파이프라인을 직접 구성해 볼 수 있었다.